阿里云 |

奥运会全球指定云服务商

扫平日志分析路上障碍: 实时日志加工实践

丁来强（成喆）- 阿里高级技术专家

议题

- 功能介绍:
  - 优势与特点
  - 解决痛点与场景
  - 功能配置与原理
- DSL语法介绍
  - 数据结构
  - 基础语法与事件类型
  - 内置函数框架
- 演示:
  - 控制台操作
  - SLB数据加工实战
  - 使用查询字符串

数据加工：面向日志分析的实时、灵活加工

阿里云 | 奥运会全球指定云服务商

源

- **200+内置函数**
- 文本处理算子
- **富化组件**
- 文本搜索算子
- **400+Grok模式**

- 代码内**自由编排**
- **组合操作**：过滤、抽取、分裂、转换、富化、分发等
- **语法简洁**

- **流式**大吞吐能力
- **实时处理**，1秒数据可见
- **计算水平扩展，按量弹性伸缩**

数据加工

- 面向日志分析场景
- 开箱即用的应用**UDF**

- 实时仪表盘，概览与统计曲线
- 异常日志
- 告警集成

- 全托管，免运维
- 与阿里云大数据产品、开源生态集成

目标(*)

数据加工：解决痛点与场景

解决数据加工的痛点

- 行业上80%的数据分析花费在数据规整上
  - 数据在接入、分析、投递、对接时存在各种需求与痛点
  - 痛点参考：
    1. 数据源混合各种格式，难以简单提取，如交换机、服务器、容器、程序Logging模块等，通过文件、stdout、syslog、网络等途径收集的数据，混合了程序的各种格式的日志；如日志中的message字段，需要根据各种情况的正则匹配后提取；
    2. 单一场景，字段动态且不确定，例如NGNIX，的QueryString、HttpCookie、HttpBody信息中的字段，需要用自动KV或者多种正则提取；
    3. 源数据包含动态JSON格式的数据（如CVE数据、O365 Audit日志等），需要动态计算，提取合并字段，甚至分裂为多条日志进行处理；
    4. 某些常规日志包含了敏感信息（例如秘钥的密码，用户手机号、内部数据库连接字符串等），很难在提取时过滤掉或者做脱敏。
    5. 使用简单表格、CSV、OSS文件、RDS、外部API等进行数据富化。

场景1 – 数据规整

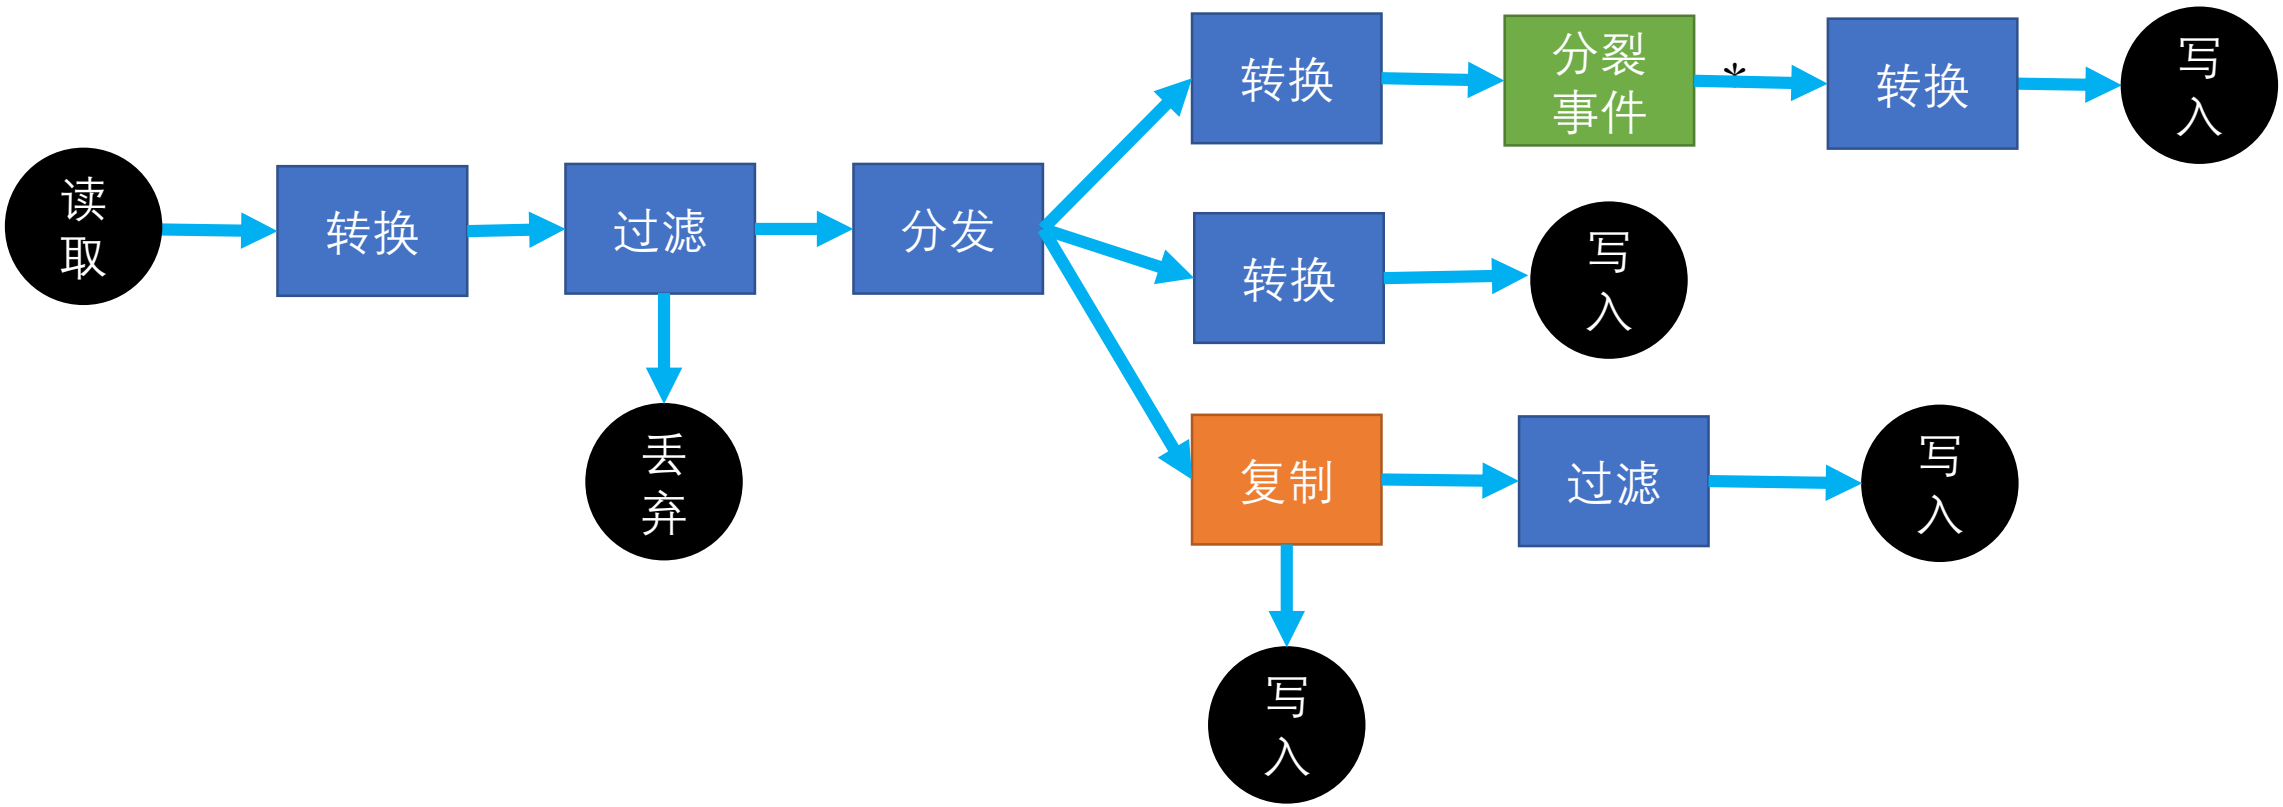

场景2 – 数据富化

源Logstore
(终端syslog日志)

```
2018-1-1 INFO user1 login server from 10.3.4.1 type=rdp
2018-1-1 INFO user2 fail to login system type=ssh IP=10.1.1.2
2018-1-3 INFO user3 use OAuth to login via O365
2018-1-3 INFO user4 login with 2 MFA {f1: mobile, f2: face}
2018-1-3 INFO user5 create project, delete object
2018-1-3 INFO user6 start process file://abc.exe
```

目标Logstore
(登录信息、
Audit信息、进程
信息)

User id	Name	Login Type	Login Date	Login Result
123123	Jane	SSH	2018-1-1	Pass

User id	Name	Op Type	Target	Result
123123	Jane	Create	project	Success

User id	Name	Process	Process id	Result
123123	Jane	Abc.exe	100	Success
123123	John	Xyz.exe	200	Fail
123123	Jack	Lass.exe	101	Success

注册用户信息

User id	Name	Device Sig	Register date	Mobile	…
123123	Jane	Nokia 100	2018-1-1	13912919191	…
123123	John	Huawei P20	2018-2-2	13912919192	…
123123	Jack	iPhone MX	2018-3-3	13912919193	…

场景3 – 数据分发

目标Logstore1
（登录信息）

User id	Name	Login Type	Login Date	Login Result
123123	Jane	SSH	2018-1-1	Pass
123123	John	RDP	2018-1-1	Fail
123123	Jack	SSH	2018-1-1	Pass

源Logstore
（App日志）

```
2018-1-1 INFO user1 login server from 10.3.4.1 type=rdp
2018-1-1 INFO user2 fail to login system type=ssh IP=10.1.1.2
2018-1-3 INFO user3 click page1 user agent
2018-1-3 INFO user3 add product id=123 into shopping cart
2018-1-3 INFO user3 click adds position x=1 y=2 width=100
```

数据加工服务

过滤、富化、转换
补漏、分裂、聚合

目标Logstore1
（浏览信息）

目标Logstore1
（下单信息）

商品信息

Product ID	Name	Spec	Price	Stock	…
111	P20	Huawei P20	200	100	…
221	iPhone	iPhone MX	300	20	…

注册用户信息

User id	Name	Device Sig	Register date	Mobile	…
123123	Jane	Nokia 100	2018-1-1	13912919191	…
123123	John	Huawei P20	2018-2-2	13912919192	…
123123	Jack	iPhone MX	2018-3-3	13912919193	…

优惠活动

- 推广期间（2019/9/30之前）：
  - 加工服务本身消耗的机器与网络资源目前免费。
  - 读取源logstore、写入目标logstore按照日志服务的标准正常收取。

功能配置、原理

源与目标

- 目前是Region化（跨Region即将推出）
- 支持跨project
- 支持跨账号
- 支持最多20个静态目标或无限动态目标

配置-授权

- 当前操作需要授权以便读取源logstore或写入目标logstore
  - 通过AK授权
  - 通过角色授权（计划推出）
- 连接第三方数据用于富化的授权通过配置中的秘钥项目完成

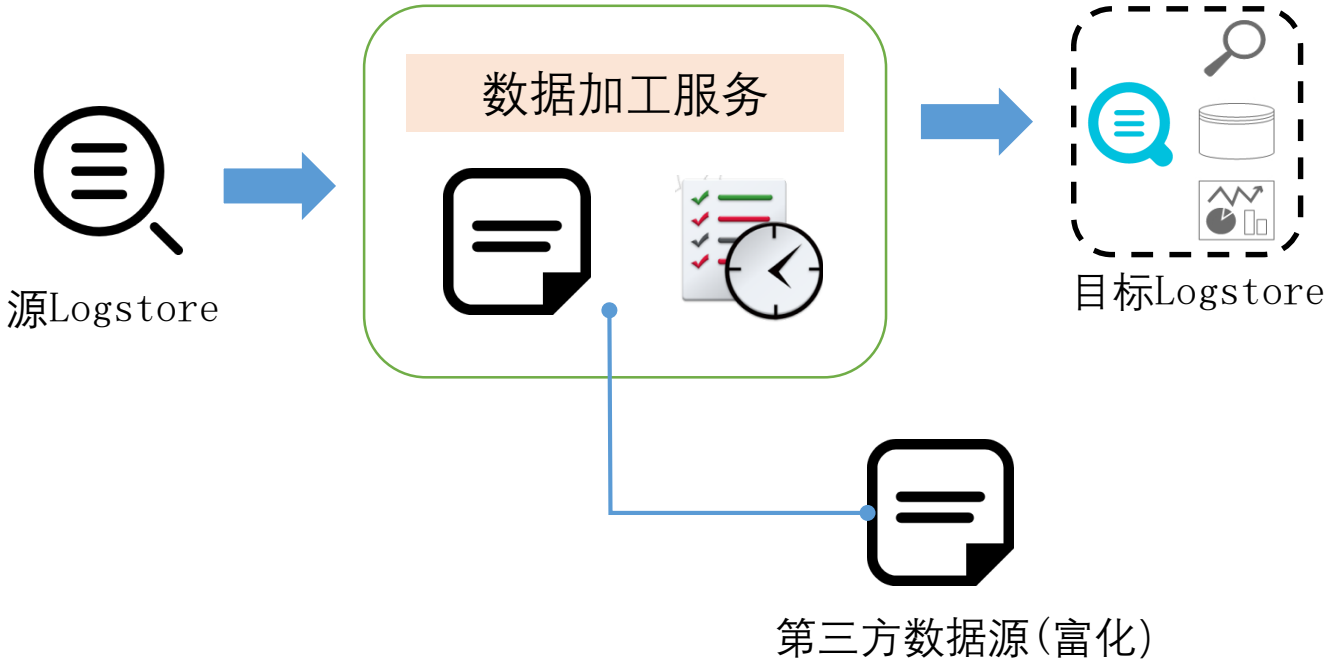

源/目标logstore最小权限

源Logstore

```
{
  "Version": "1",
  "Statement": [
    {
      "Action": [
        "log:ListShards",
        "log:GetCursorOrData",
        "log:GetConsumerGroupCheckPoint",
        "log:UpdateConsumerGroup",
        "log:ConsumerGroupHeartBeat",
        "log:ConsumerGroupUpdateCheckPoint",
        "log:ListConsumerGroup",
        "log:CreateConsumerGroup"
      ],
      "Resource": [
        "acs:log:*:*:project/源project/logstore/源logstore",
    "acs:log:*:*:project/源project/logstore/源logstore/*"
      ],
      "Effect": "Allow"
    }
  ]
}
```

目标Logstore

```
{
  "Statement": [
    {
      "Action": [
        "log:Post*"
      ],
      "Effect": "Allow",
      "Resource": "acs:log:*:*:project/目标Project/logstore/目标Logstore"
    }
  ],
  "Version": "1"
}
```

调度规则

方案与特点	持续加工	一次性加工
消费范围（配置）	消费时间起点（**日志接收时间**或begin）- 仅在初次消费时有用	时间起止点（**日志接收时间范围**）
启动与消费行为	启动后从指定点开始消费，持续下去，不会停止（除非人介入）	启动后消费指定范围（或无数据）后停止 – **任务结束**
实时性	实时	非实时
适用场景	常规实时加工	历史数据加工或特定场景（如校验、测试、演示等）

自由编排DSL

200+函数，400+GROK模式

自由组合

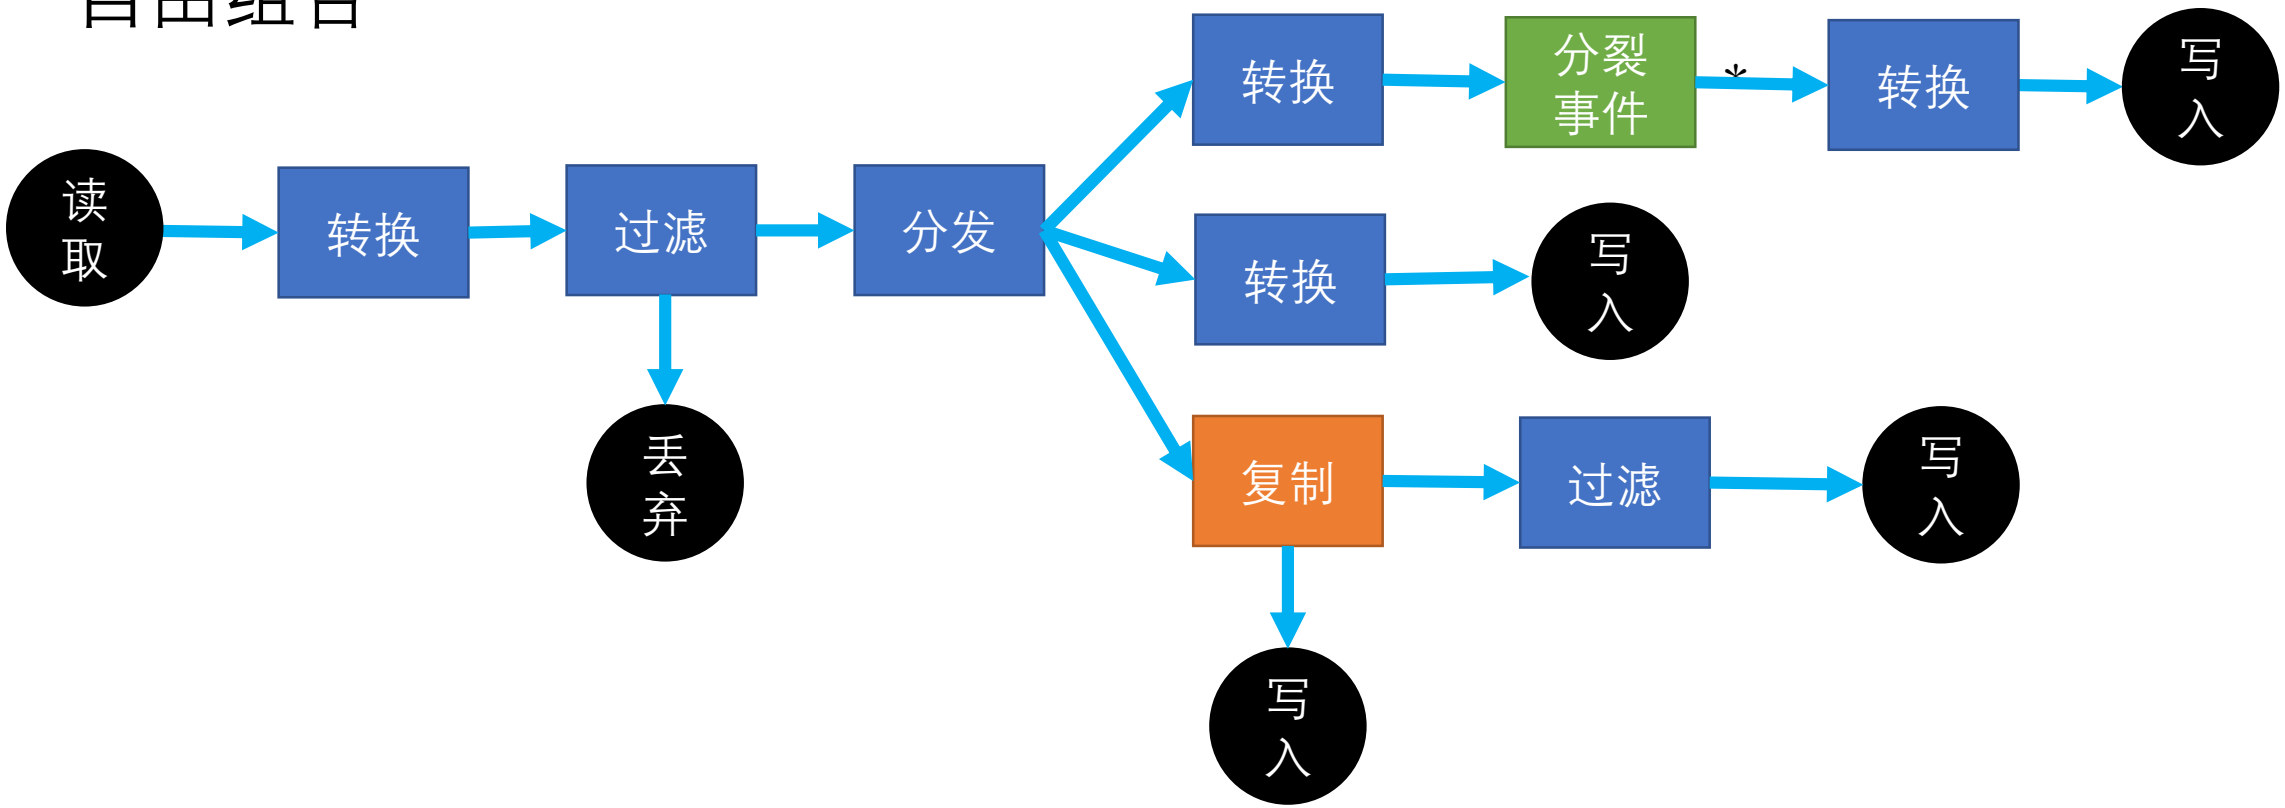

数据加工DSL能力

- 语法简洁且支持UDF(内部)
- 30+全局函数
- 200+内置函数
- 数学/文本/时间/IP/处理算子
- OSS/Logstore/RDS-MySQL/IP库/配置资源连接器
- 400+Grok模式
- 类Lucene事件搜索算子
- JMES语法支持
- 代码内自由编排
- 组合操作：过滤、抽取、分裂、转换、富化、分发等

类型	函数	说明
流程控制	e_if	多个条件操作的配对操作
流程控制	e_if_else	if-else操作
流程控制	e_switch	满足一个条件操作后跳出
流程控制	e_compose	组合操作
事件操作	e_drop	丢弃
事件操作	e_keep	保留
事件操作	e_split	分裂
事件操作	e_output	输出
事件操作	e_coutput	复制输出
字段操作	e_drop_fields	删除
字段操作	e_keep_fields	保留
字段操作	e_rename	重命名
字段值赋值	e_set	赋值
字段值提取	e_regex	正则提取
字段值提取	e_json	json展开或提取
字段值提取	e_kv	自动提取键值对
字段值提取	e_kv_delimit	基于分隔符提取键值对
字段值提取	e_csv	逗号或其他分隔符提取
字段值提取	e_tsv	tab分隔符提取
字段值提取	e_psv	pipe分隔符提取
字段值提取	e_syslogrfc	根据syslog协议提取头
字段富化	e_dict_map	字典映射
字段富化	e_table_map	表格映射
字段富化	e_search_map	搜索映射
任务配置	res_local_update	设置任务参数上下文

类型	函数	说明
事件检查函数	v, e_has, e_not_has, e_search, e_match, e_match_any, e_match_all等	获取事件字段值，或判断字段或字段值是否符合特定内容
操作符函数	部分`op_*`函数	比较，条件判断，容器类计算，一般性多值操作
转换函数	`ct_*`函数	数字,字符串,布尔之间的转换，数字进制转换
算术函数	部分`op_*`函数，`math_*`函数等	数字的`+-*/`幂等计算，数学计算，多值计算等
字符串函数	`str_*`函数	字符串的所有相关操作与判断搜索等
日期时间函数	`dt_*`函数	Unix时间戳，日期时间对象，日期时间字符串转化，时区调整，圆整等
正则表达式函数	`reg_*`函数	正则提取，检索，替换，分裂多值等
GROK函数	`grok`函数	提取grok模式返回对应正则表达式
JSON, XML, Protobuf函数	`json_*`，`xml_*`，`pb_*`函数	对应提取或解析
编码解码类函数	`url_*`，`html_*`，`md5_*`，`sha1_*`，`base64_*`函数	相关单向或双向函数
列表函数	`lst_*`函数	列表相关构建,获取，修改，操作等
字典函数	`dct_*`函数	字典相关构建,获取，修改，操作等
表格函数	`tab_*`函数	从文本解析出表格，表格转字典等
资源函数	`res_*`函数	本地配置，RDS，Logstore等资源获取

调度原理

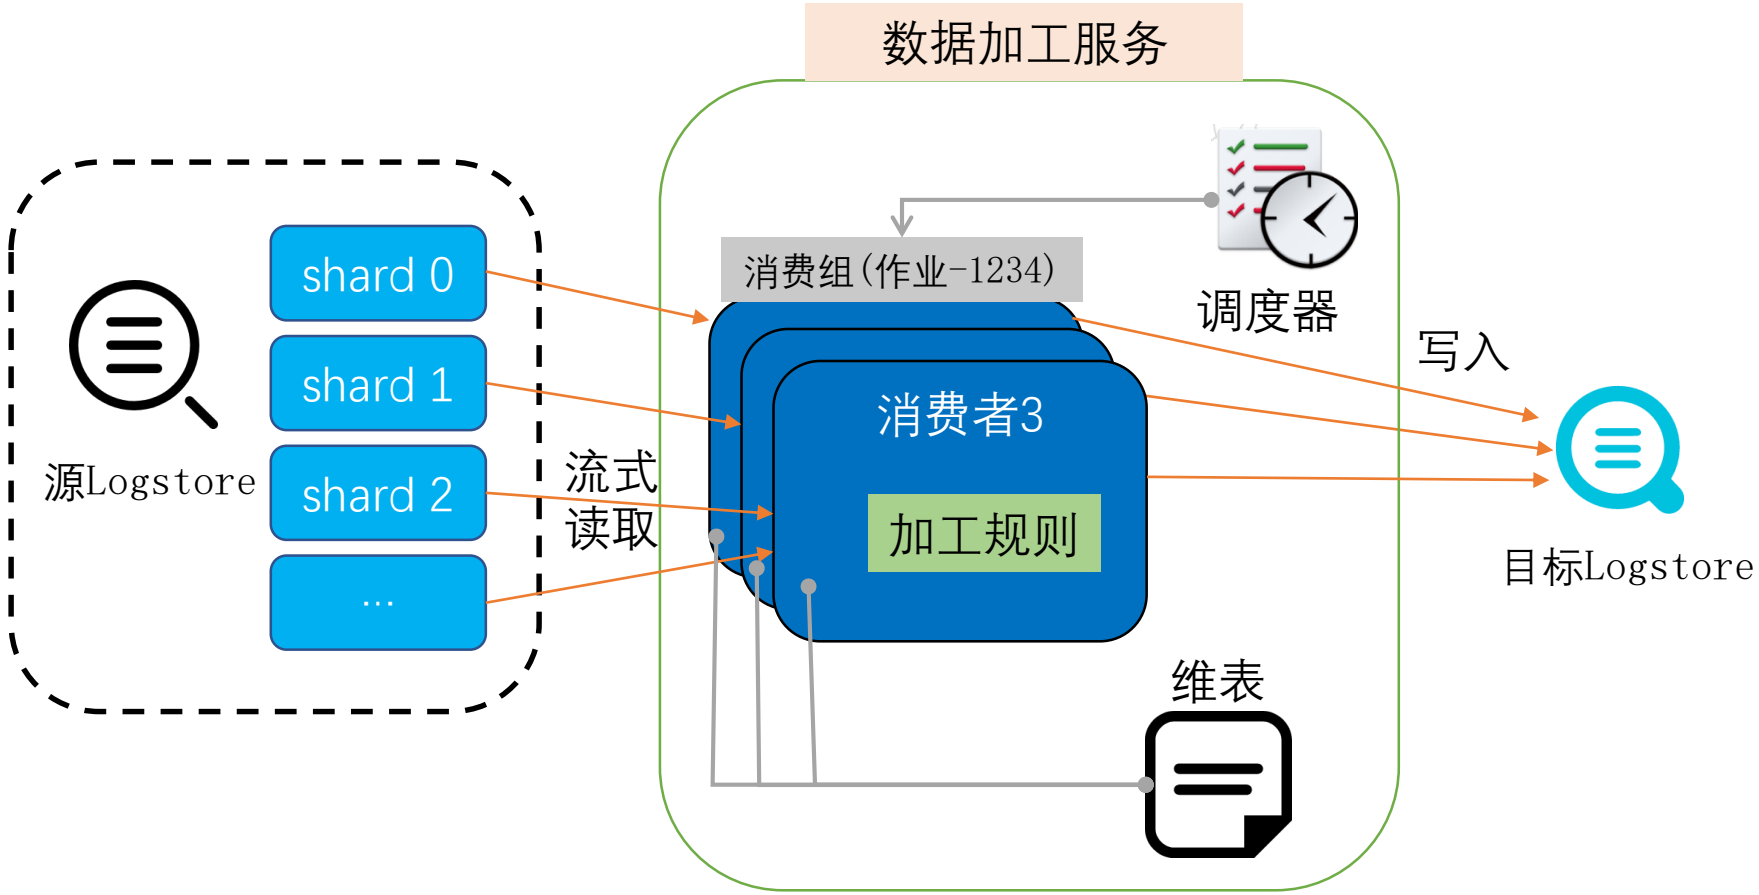
数据加工服务
shard 0
shard 1
shard 2
...
源Logstore
流式
读取
消费组(作业-1234)
消费者3
加工规则
调度器
写入
目标Logstore
维表

DSL语法介绍

兼容Python的DSL

类别	Python语法	DSL语法
数据结构	数字, 字符串, 布尔	支持, 除"""形式字符串不支持
数据结构	元祖, 列表, 集合, 字典	支持, 除集合set如{1,2,3}不支持
数据结构	对象定义	仅支持内置扩展数据结构,如表格, 日期时间对象等
基本语法	操作符, 如加减乘除等	不直接支持, 需要通过函数方式支持
基本语法	注释	支持
基本语法	变量定义赋值	不支持, 需使用无状态方式调用传递
基本语法	条件、循环	不直接支持， 控制逻辑通过内置函数实现
函数	标准Python内置函数	不支持, 使用内置200+函数
函数	函数调用	支持, 除解包调用不支持
函数	自定义函数def或lambda	不支持, 提供200+事件与表达式函数, 支持自由组合调用
模块	导入与使用Python标准库	不支持（特殊需求可提工单）
模块	线程与进程创建	不支持（特殊需求可提工单）
模块	导入第三方库	不支持（特殊需求可提工单）
模块	外部网络连接或命令调用	提供内置的资源连接器

基本数据结构

整数、浮点、布尔、空

- 整数
  - e_set("f1", 100)
- 浮点
  - e_set("f1", 1.5)
- 布尔
  - True, False, true, false
- 空
  - None 或 null, 表示无(不同于空字符串)
  - 许多函数也以None为命名参数的默认值.
  - 函数返回时表示空(全局事件函数以返回None表示删除)

字符串

- 字符串
  - "abc"等价于'abc'
  - 字符\用于转义，自身为\\或者r修饰
  - 宽字符友好，例如"你好"的长度也是2.
  - 正则表达式以字符串表示，常用r修饰

列表、元祖、字典

- 列表
  - 也叫数组，形式：[1,2,3,4]
  - 函数可能接受或返回列表，例如e_dict_map、json_select
- 元组(tuple)
  - 形式：(1, 2, 3, 4)
  - 和列表功能一样, 某些函数参数使用元组形式
- 字典
  - 形式为 {"key": "value", "k2": "v2", ...} 的键值对组合
  - 关键字一般是字符串, 值可以是任何支持的数据结构
  - 存储格式以哈希方式, 关键字不能重复. 遍历查询时无序.
  - **事件是一种特殊的字典**

其他对象

- 表格
  - 多列的表格结构
  - 可以CSV格式内容构建, 或者从RDS, Logstore拉取
  - 一般传递给接收表格作为参数的函数， 如e_table_map, tab_to_dict等
- 日期时间对象
  - 表示日期时间的内存对象
  - 某些时间类函数会接收或返回
- 字节
  - b'abc'不同于字符串的内存编码形式. 某些特殊函数接收或者返回.

JSON对象

- 一般指JSON表达式函数json_select或者json_parse解析提取后的对象，并没有真正JSON对象

原始字符串	解析出的JSON对象	实际类型
1	1	整数
1.2	1.2	浮点
true	True	布尔
false	False	布尔
"abc"	"abc"	字符串
null	None	None
["v1", "v2", "v3"]	["v1", "v2", "v3"]	列表
["v1", 3, 4.0]	["v1", 3, 4.0]	列表
{"v1": 100, "v2": "good"}	{"v1": 100, "v2": "good"}	字典
{"v1": {"v11": 100, "v2": 200}, "v3": "good"}	{"v1": {"v11": 100, "v2": 200}, "v3": "good"}	字典

基础语法

注释、换行

- 注释 （# 开头）

```
# 设置默认主题（放在行首的注释）
e_set("__topic__", "access_log")    # 设置默认主题（放在行尾的注释）
```

- 换行:
  - 使用\衔接换行
  - 在,的地方可以直接换行（例如函数参数）

```
e_set("__topic__", "this is a very long long long ..........." \
                           "......long text")

e_set("__topic__", "v1",
          "type", "v2",                  # 逗号分隔的可以直接换行
          "length", 100)
```

操作符

场景操作	函数	样例
加 +	op_add	op_add(v("age"), 2)
减 -	op_sub	op_sub(v("age"), 2)
乘 *	op_mul	op_mul(v("size"), 2)
幂 **	op_pow	op_pow(v("size"), 2)
整除 //	op_div_floor	op_div_floor(v("bytes"), 1024)
取模 %	op_mod	op_mod(v("age"), 10)
取负 -	op_neg	op_neg(v("profit"))
判断存在 in	op_in	op_in(["pass", "ok"], v("result"))
判断不存在 not in	op_not_in	op_in(["pass", "ok"], v("result"))
逻辑且 and	op_and	op_and(op_gt(v("age"), 18), op_lt(v("age"), 31))
逻辑或 or	op_or	op_or(op_le(v("age"), 18), op_gt(v("age"), 65))
逻辑否 not	op_not	op_not(op_gt(v("age"), 18))
判断等于 ==	op_eq	op_eq(v("name"), "xiao ming")
判断不等于 !=	op_ne	op_ne(v("name"), "xiao ming")
大于 >	op_gt	op_gt(ct_int(v("age")),)
大于等于 >=	op_ge	op_ge(ct_int(v("age")), 18)
小于	op_lt	op_lt(ct_int(v("age")), 18)
小于等于 <=	op_le	op_le(ct_int(v("age")), 18)
字符串切片 [...]	op_slice	op_slice(v("message"), 0, 20)

```
# *
e_set("a", 3600 * 6)    # 非法
e_set("a", op_mul(3600, 6))    # 合法

# /
e_set("bytes_kb", v("bytes") / 1024)    # 非法
e_set("bytes_kb", op_div_floor(v("bytes"), 1024))    # 合法
```

函数调用方式

- 基本调用方式:
  - e_set("abc", "xyz")
    - 非命名参数一般都需要传递所有值.
- 命名参数调用方式:
  - e_set("abc", "xyz", mode="fill")
  - 命名参数不传递, 会使用默认值.
  - 多个命名参数下, 可以根据选择传递, 顺序不要求(以下一样) :
    e_csv("data", ["f1", "f2", "f3"], sep='#', quote="|")
    e_csv("data", ["f1", "f2", "f3"], quote="|", sep='#‘)
    - 注意: 命名参数的顺序, 始终在非命名参数的后面.

函数调用方式（2）

- 变参
  - 某些函数支持变参传递, 例如:
    e_set("k1", "v1", "k2", "v2", ...)
  - 带命名参数时, 命名参数放最后:
    e_set("k1", "v1", "k2", "v2", ..., mode="fill")
- 组合调用
  - 参数是其他函数的调用方式
    e_set("abc", v("xyz"))
    e_set("abc", str_lower(v("xyz")))

真假判断

数据类型	True的条件	False的条件
布尔	True, true	False, false
None	-	总是False
数值	非0, 0.0	0, 0.0
字符串	非空	空串
字节	非空	空字节
元组	非空	空元组
列表	非空	空列表
字典	非空	空字典
表格	存在即为True	空对象(None)
日期时间	存在即为True	空对象(None)

```
e_if(True, DROP)                # 总是
e_if(1, DROP)                   # 总是
e_if(v("abc"), DROP)        # 存在字段abc，且字段不为空时
e_if(str_isdigit(v("abc")), DROP) # 存在字段abc，且字段的内容都是数字时
```

事件类型

基本类型

- 数据加工的日志的数据结构是以**字典**
  - 例如{"__topic__": "access_log", "content": "....."}
- 字典的关键字和值, 对应于日志的字段和值
- 注意: 事件的关键字和值都是字符串.
- 注意: 关键字不能重复.
- **事件类的函数**会自动接收事件

元字段

- 时间字段: __time__: 是Unix时间戳的**字符串**
- 其他的有
  - 主题: __topic__
  - 源: __source__
- 时间字段修改
  - 修改这个字段的值, 等于修改了日志的事件时间.
    - 可以使用**时间函数**对齐进行进一步的各种操作.
  - 删除了这个字段, 等于重置了时间
    - 在输出日志时, 会自动用当前时间.

标记（tag）

- 不同于一般字段, 格式为__tag__:名称
  - 如果源logstore打开了服务器接收时间的日志, 则会存在tag: __tag__:__receive_time__
  - K8S的日志会存在许多容器类的tag, 例如: __tag__:__container_name__
- 可以自由添加Tag:
  - e_set("__tag__:type", "access_log")
  - 或者在e_output、e_coutput时设置tag

赋值自动转换

- 注意: 事件的关键字和值都是字符串，提取或设置时，会自动转换为字符串

类型	样例	转换类型	转换样例
整数	1	字符串	"1"
浮点	1.2	字符串	"1.0"
布尔	True	字符串	"true"
字节	b"123"	使用UTF8反转为字符串	"123"
元组	(1, 2, 3)	json转换	"[1, 2, 3]"
列表	[1,2,3]	json转换	"[1, 2, 3]"
字典	{"1":2, "3":4}	json转换	"{"1": 2, "3": 4}"
日期时间	datetime(2018, 10, 10, 10, 10)	ISO格式转换	2018-10-10 10:10:10

```
e_set("v1", 12.3)
e_set("v2", True)
```

固定标示

- 方便使用

类型	标示	说明
布尔	true	真, 等价于True
布尔	false	假, 等价于False
None	null	无, 等价于None
字符串	F_TAGS	TAG字段正则表达式, 等价于"__tag__:.+"
字符串	F_META	topic, source, TAG字段的正则表达式表示, 等价于 __tag__:.+|__topic__|__source__
字符串	F_TIME	time字段的名称, 等价于__time__
字符串	F_PACK_META	pack meta字段的正则表达式表示形式, 等价于 "__pack_meta__|__tag__:__pack_id__"
字符串	F_RECEIVE_TIME	服务器接收时间的tag字段, 等价于"__tag__:__receive_time__"

内置函数框架

内置函数

- 全局操作函数
  - 只有全局操作函数才能构建加工规则的每一步骤.
  - 接收事件, 处理并返回事件的函数

```
全局函数1(..参数....)
全局函数2(..参数....)
全局函数3(..参数....)
全局函数4(..参数....)
```

- 表达式函数
  - 通用型函数, 接收特定参数, 组合调用后作为传递给全局操作函数以定义更加灵活逻辑.

```
全局操作1(表达式函数1(...), ....)
全局操作2(..., 表达式函数2(...), 表达式函数3(...),...)
```

两者区别

特点	全局操作函数	表达式函数
可做全局步骤	是	否
接收	自动接收事件	除个别**大部分不自动**接收事件
返回	0到多条事件	特定数据结构
修改事件	大部分会	不会
可否组合调用	可以	可以

全局操作函数概览

类型	函数	说明
流程控制	e_if	多个条件操作的配对操作
	e_if_else	if-else操作
	e_switch	满足一个条件操作后跳出
	e_compose	组合
事件操作	e_drop	丢弃
	e_keep	保留
	e_split	分裂
	e_output	输出
	e_coutput	复制输出
字段操作	e_drop_fields	删除
	e_keep_fields	保留
	e_rename	重命名

类型	函数	说明
字段值赋值	e_set	赋值
字段值提取	e_regex	正则提取
	e_json	json展开或提取
	e_kv	自动提取键值对
字段值提取	e_kv_delimit	基于分隔符提取键值对
	e_csv	逗号或其他分隔符提取
	e_tsv	tab分隔符提取
	e_psv	pipe分隔符提取
	e_syslogrfc	根据syslog协议提取头
字段富化	e_dict_map	字典映射
	e_table_map	表格映射
	e_search_map	搜索映射
资源操作	res_local_update	设置任务参数上下文

表达式函数概览

类型	函数	说明
事件检查函数	v, e_has, e_not_has, e_search, e_match, e_match_any, e_match_all等	获取事件字段值, 或判断字段或字段值是否符合特定内容
基础操作函数	部分op_* 函数	比较, 条件判断, 容器类计算, 一般性多值操作
转换函数	ct_*函数	数字,字符串,布尔之间的转换, 数字进制转换
算术函数	部分op_*函数, math_*函数等	数字的+-*/幂等计算, 数学计算, 多值计算等
字符串函数	str_*函数	字符串的所有相关操作与判断搜索等
日期时间函数	dt_*函数	Unix时间戳, 日期时间对象, 日期时间字符串转化, 时区调整, 圆整等

类型	函数	说明
正则表达式函数	reg_*函数	正则提取, 检索, 替换, 分裂多值等
GROK函数	grok函数	提取grok模式返回对应正则表达式
JSON, XML, Protobuf函数	json_*, xml_*, pb_*函数	对应提取或解析
编码解码类函数	url_*, html_*, md5_*, sha1_*, base64_*函数	相关单向或双向函数
列表函数	lst_*函数	列表相关构建,获取, 修改, 操作等
字典函数	dct_*函数	字典相关构建,获取, 修改, 操作等
资源函数	res_*函数	本地配置, RDS, Logstore等资源获取

规则引擎原理：基本操作

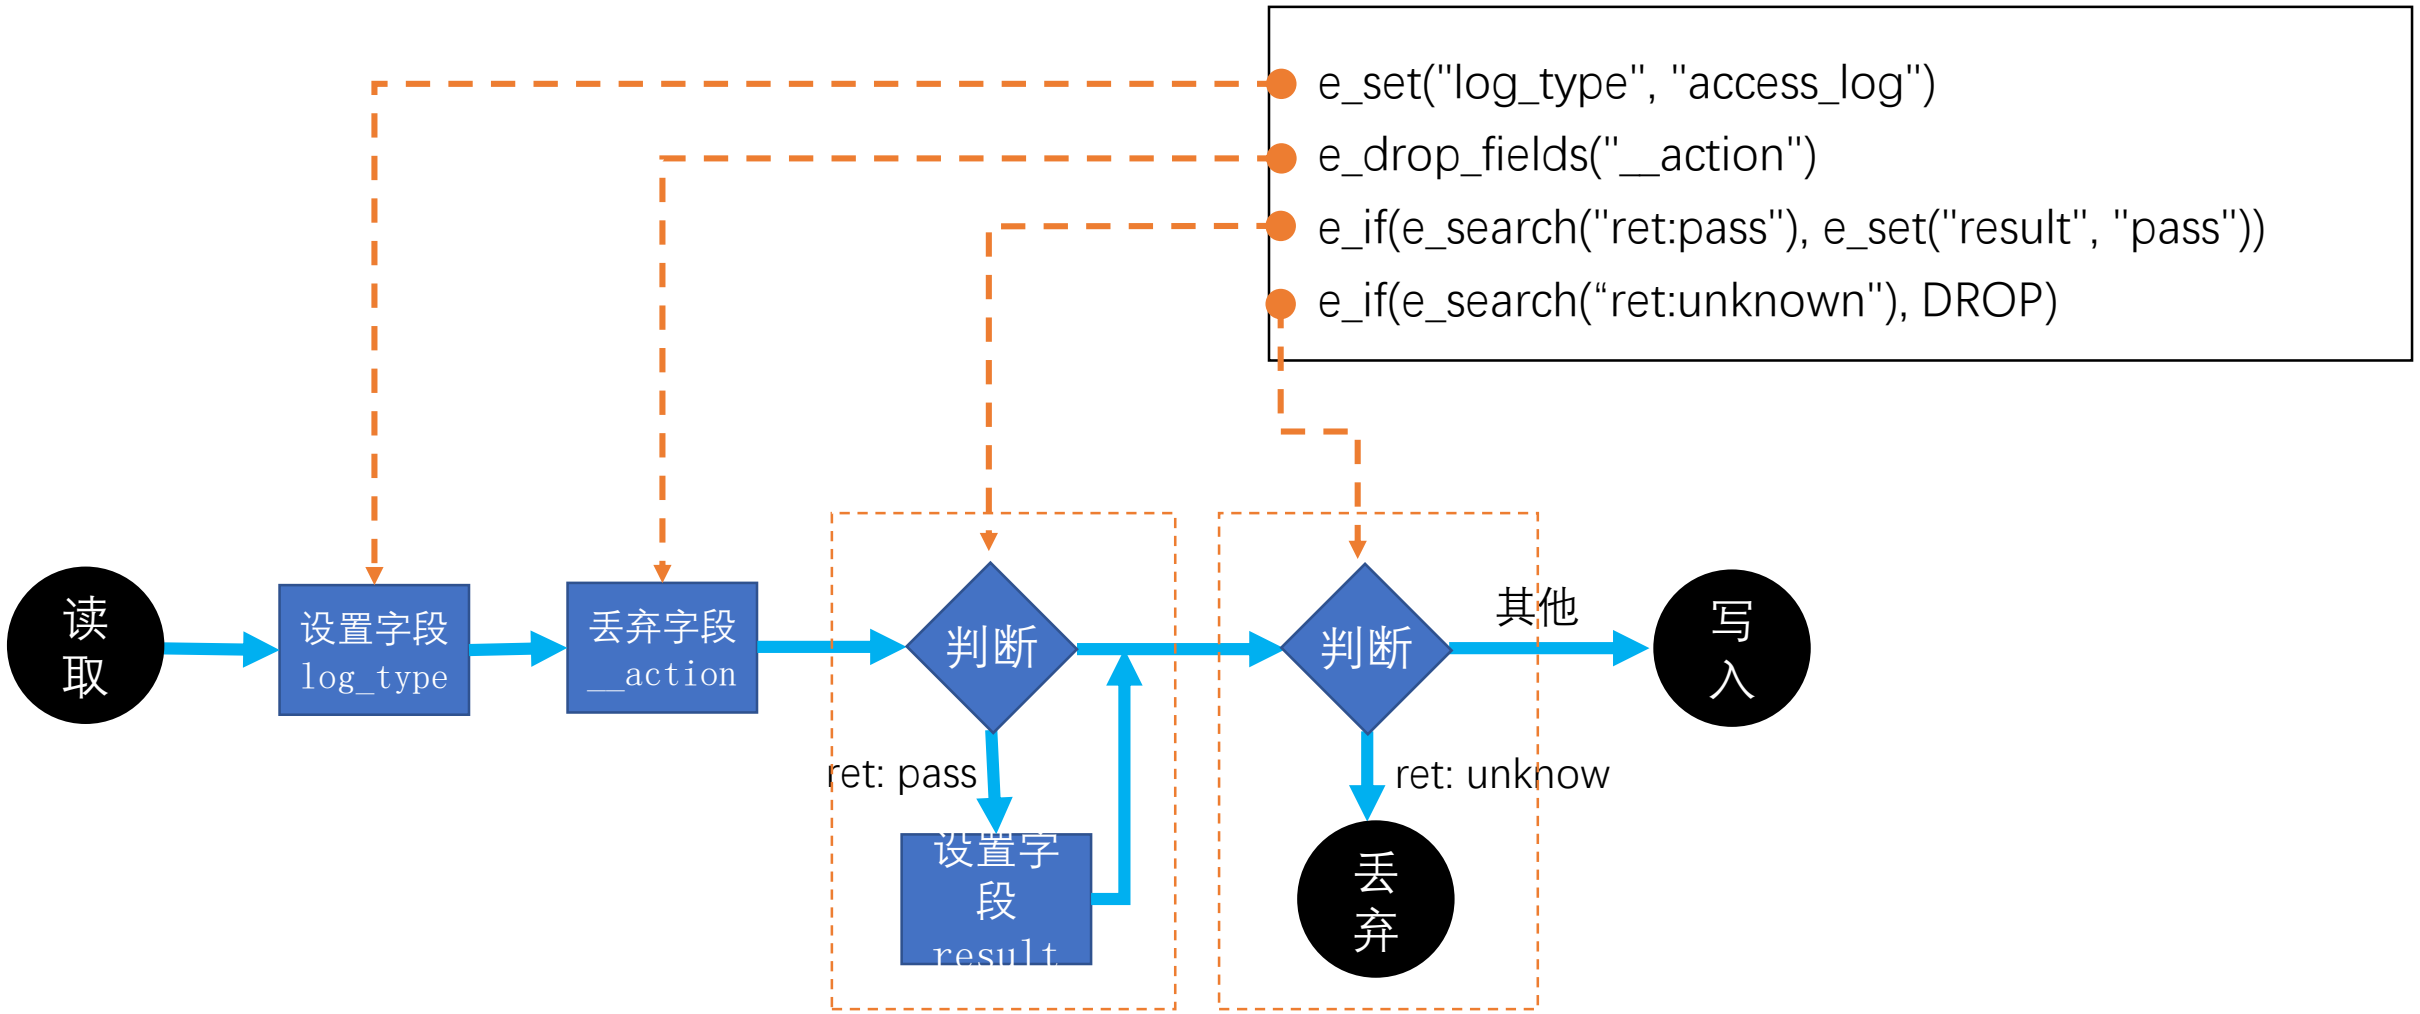

规则引擎原理：输出，复制与分裂

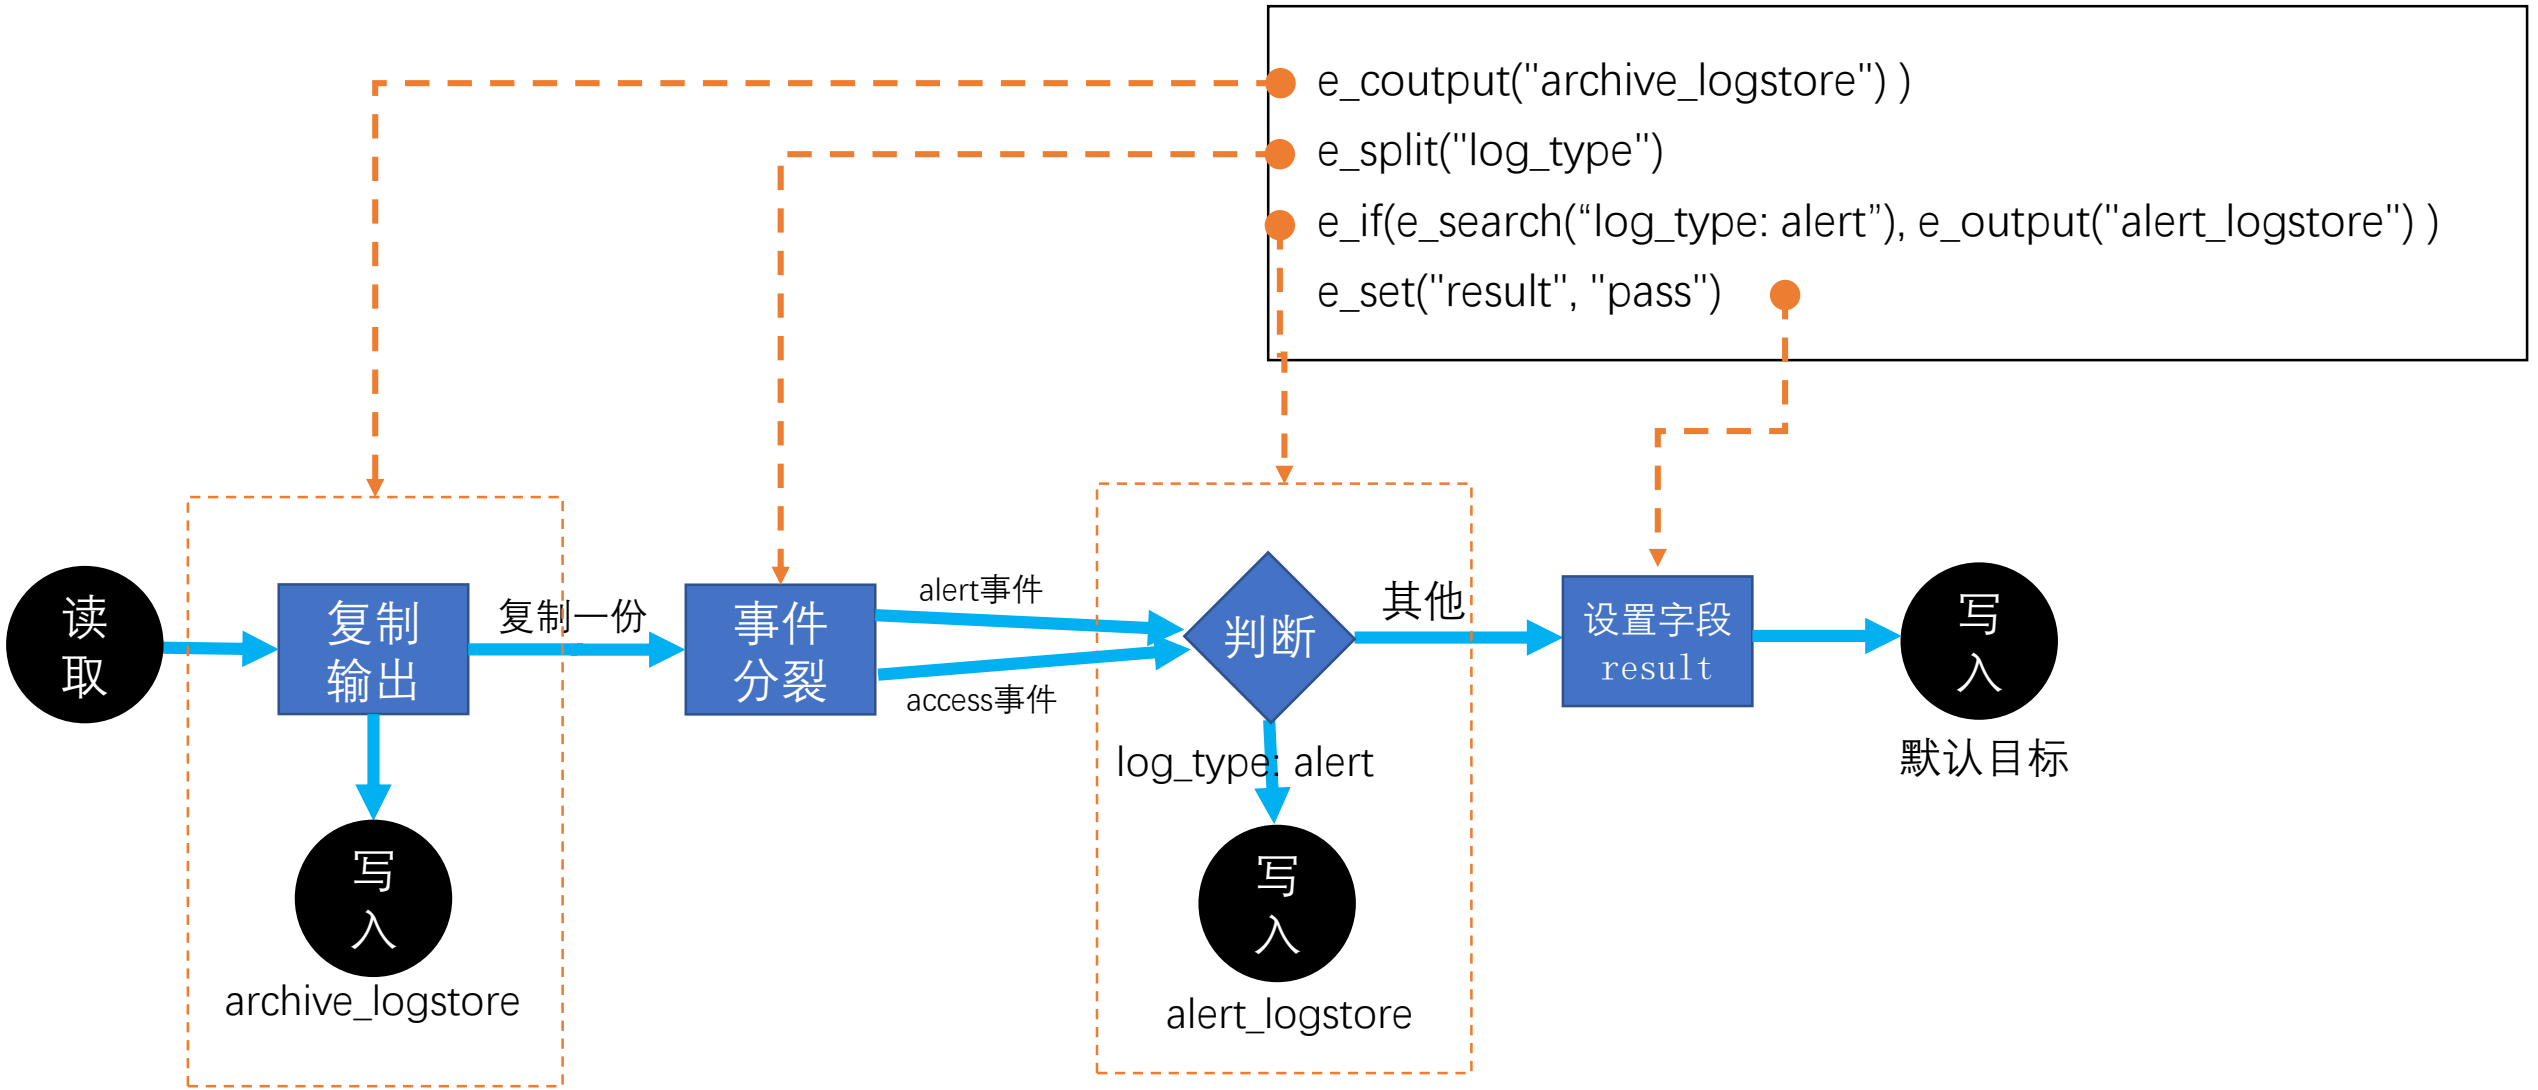

Demo

Demo

1. 控制台操作
2. SLB加工操作
3. 函数浏览
4. 查询字符串语法

SLB加工

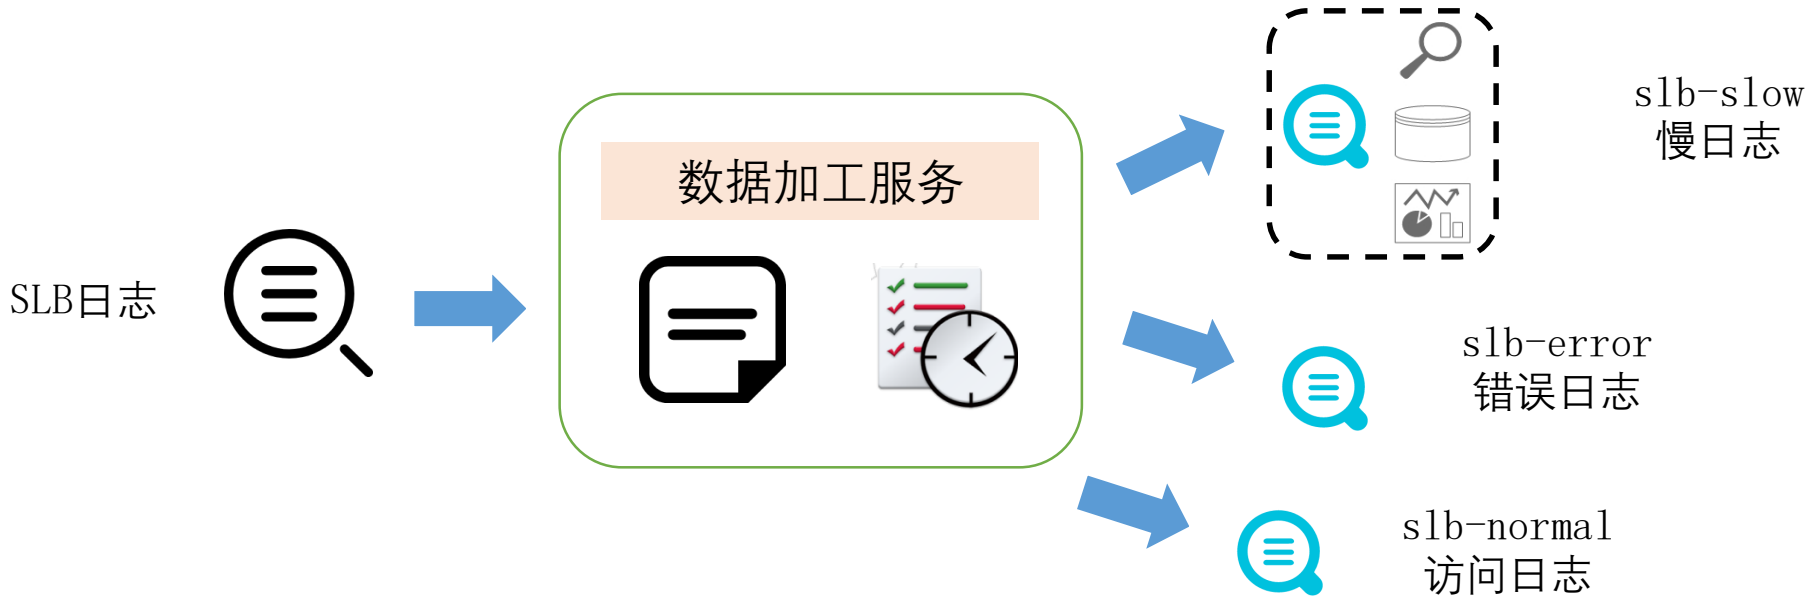

查询字符串语法

相关函数

类型	函数	使用场景
表达式函数-事件判断函数	e_search	使用查询字符串判断事件的字段值是否满足特定条件, 返回True或False
表达式函数-资源函数	res_log_logstore_pull	拉取Logstore资源返回表格结构, 支持使用查询字符串配置黑白名单对行进行过滤筛选.
表达式函数-资源函数	res_rds_mysql	拉取RDS-MySQL资源返回表格结构, 支持使用查询字符串配置黑白名单对行进行过滤筛选.
全局事件函数-搜索表格映射	e_search_table_map	关键字是查询字符串, 值是匹配的值的字典进行映射

功能概览

功能	字段	全文
子串搜索	支持	支持
通配符*?搜索	支持	支持
完全匹配搜索	支持	-
正则表达式搜索	支持	-
数值范围搜索	支持	-
数值比较	支持	-
关系and, or, not以及自由组合	支持	支持

子串搜索

```
e_search("子串")
e_search("字段名: 子串")
```

全文搜索

样例	场景
e_search("active error")	多个子串搜索, 默认关系是OR
e_search('"active error"')	搜索完整带空格的子串
e_search('"错误"')	中文子串

字段搜索

样例	场景
e_search("status: active")	子串搜索
e_search('author: "john smith"')	带空格子串搜索
e_search('fileId: active error')	相当于 field:active OR "error"

通配符搜索

- * ? 匹配: *表示 0个或多个字符串, ? 表示一个字符, 也可以表示一个宽字符如中文.

全文搜索

样例	场景
e_search("active*test")	匹配0到多个, 不需要用双引号括起来
e_search("发生*错误")	中文匹配, 可以匹配发生错误, 发生严重错误等
e_search("active?good")	? 可以不用双引号
e_search("ac*tive?good")	也可以应用于完全匹配
e_search("ac*tive??go*od")	支持多个混合使用

字段搜索

样例	场景
e_search("status: active*test")	匹配0到多个
e_search("status: active?good")	匹配一个

完全匹配

```
e_search("字段名==子串")
```

样例	场景
e_search('author== "john smith"')	字段author必须完全等于john smith
e_search("status== ac*tive?good")	可以与通配符结合使用

正则表达式匹配

```
e_search("字段名~=正则表达式字符串")
```

样例	场景
e_search(r'status~= "\d+"')	status字段包含数字
e_search(r'status~= "^\d+$"')	status字段等于数字

数值比较

- 范围类比较

```
e_search('count: [100, 200]')   # >=100 and  <=200
e_search('count: [*, 200]')   # <=200
e_search('count: [200, *]')   # >=200
```

- 数值直接比较

```
e_search('age >= 18')   # >= 18
e_search('age > 18')   #  > 18
e_search('age = 18')   #  = 18
e_search('age <= 18')   #  <=18
e_search('age < 18')   #  <18
```

逻辑关系

- 支持任意搜索之间的逻辑关系, 也支持用 ( ) 进行嵌套.

逻辑	关键字
且	and AND && 大小写不敏感
或	or OR
否	not ! 大小写不敏感

全局逻辑关系

```
e_search("abc OR xyz")  # 大小写不敏感
e_search("abc and (xyz or zzz)")
e_search("abc and not (xyz and not zzz)")
e_search("abc && xyz")    # and
e_search("abc || xyz")    # or
e_search("abc || !xyz")   # or not
```

逻辑关系（2）

字段逻辑关系

```
e_search("field: (abc OR xyz)")  # 字段field包含 abc 或 xyz
e_search("field: (abc OR not xyz)")  # 字段field包含 abc 或 不包含xyz
e_search("field: (abc && !xyz)")  # 字段field包含 abc 且 不包含xyz
```

字段判断

样例	场景
e_search("field: *")	字段存在
e_search("not field:*")	字段不存在
e_search('not field:""')	字段不存在
e_search('field: "?"')	字段存在, 且值不为空
e_search('field==""')	字段存在, 且值为空
e_search('field~=".+"')	字段存在, 值不为空
e_search('not field~=".+"')	字段不存在或值为空
e_search('not field==""')	字段不存在或值不为空

字段名转义

- **字段名不能使用双引号**：包含特殊字符时直接使用\转义，
  - 包含中文，字母，数字，下划线，小横线等情况不需要用**双引号**，其他情况需要.
    - **__tag__\:__container**_name__**: abc**
    - 中文字段: 错误
  - 错误：
    "content": abc

- 值用字符串用**双引号**括起来，**不支持单引号**
  - 错误： e_search("domain: '/url/test.jsp'")
  - 正确： e_search('domain: "/url/test.jsp"')

搜索值转义

- 值包含"\时需要用\转义.
  - 例如:content: "abc\"xy\\z" 合法
- 希望搜索字符*?时, 也需要用\转义, 否则会被视为通配符匹配
- 中文, 字母, 数字, 下划线, 小横线, *, ?等情况不需要用双引号, 其他情况需要用双引号括起来.
  - status: "*\?()[]:=" 值含特殊字符的值, 推荐放在"中, 除了*?和\需要转义外, 其他不用转义
  - status: active*test 值只包含*或?, 可以不用双引号
  - status: active\?test 值只包含*或?, 可以不用双引号
  - content: ()[]:= 非法

注意点

```
f1: "abc xyz"
表示：字段f1里面搜索子串"abc xyz"

f1: (abc xyz)
f1: abc or f1: xyz  # 等价于
表示：字段f1里面搜索abc或xyz

f1: (abc and xyz)
f1: abc and f1: xyz # 等价于
表示：字段f1里面搜索abc且xyz
```

```
f1: abc and xyz
(f1: abc) and (xyz)  # 等价于
表示：字段f1里面搜索"abc"，且全文搜索xyz

f1: abc xyz
f1: abc or xyz       # 等价于
(f1: abc) or (xyz)   # 等价于
表示：字段f1搜索abc，或全文搜索xyz
```

最佳实践

基础

- 函数调用最佳实践
- 事件判断最佳实践
- 日期时间处理最佳实践

分发汇总

- 数据分发: 跨账号多目标logstore数据分发
- 数据汇总: 跨账号多源logstore数据汇总

非结构化文本解析

- 解析syslog协议框架: 解析syslog/Rsyslog的标准格式
- 一般性文本: 使用正则表达式与grok解析Ngnix日志
- 动态KV: 动态键值对KV解析
- 特定格式的: 特定格式文本的数据加工

持续更新
https://yq.aliyun.com/articles/712381

结构化文本解析

- 复杂JSON格式加工:
  - 多子键为数组的复杂JSON
  - 多层数组对象嵌套的复杂JSON
- CSV格式的: 解析CSV格式的日志

数据富化

- 构建字典与表格
- 从RDS-MySQL获取数据
- 从其他logstore获取数据
- 使用搜索映射做高级数据富化

阿里云开发者社区

日志服务数据加工系列培训

主题：扫平日志分析路上障碍，实时海量日志加工实践培训

讲师：丁来强（成喆）- 阿里高级技术专家 | 唐恺(风毅) - 阿里技术专家

分享介绍

8月7日 19:30-20:30	8月8日 19:30-20:30	8月13日 19:30-20:30	8月14日 19:30-20:30	8月20日 19:30-20:30	8月21日 19:30-20:30	8月28日 19:30-20:30	8月29日 19:30-20:30
数据加工 介绍与实战	数据加工DSL 核心语法介绍	数据加工DSL 语法实践	数据加工动态 数据分发汇集实践	非结构化数据 解析实践	结构化数据 解析实践	数据映射 富化实践	数据加工 可靠性与排错实践

奥运会全球指定云服务商